Задание #3

Произведите кластеризацию для набора данных train_stations_europe.csv. Используйте встроенные реализации алгоритмов из библиотек (sklearn, scipy) и инструменты matplotlib для построения визуализаций.

1. Примените алгоритм DBSCAN для кластеризации всех железнодорожных станций, метрика — расстояние между их географическими координатами. Регулируя параметры модели (eps и min_samples), постарайтесь получить разумное число кластеров и покрыть ими хотя бы 70-80% объектов. После этого постройте визуализацию полученного распределения станций по кластерам.

Проанализируйте результаты: определите, какие страны имеют наибольшую доли покрытия, а в каких оказалось больше всего «шумовых» станций. Сделайте выводы о поведении алгоритма на всех данных, опираясь на ваши результаты и визуальное распределение станций.

2. Выберите любую страну, в которой расположено достаточное количество железнодорожных станций (хотя бы несколько сотен), и отделите подвыборку с данными только об этой стране. Для подвыборки примените один из алгоритмов на выбор:

- K-means (число кластеров подберите с помощью метода локтя)
- Иерархическая кластеризация (число кластеров подберите с помощью дендрограммы)

После этого примените для вашей подвыборки алгоритм DBSCAN, подберите параметры модели так, чтобы получить число кластеров, близкое к числу из прошлого алгоритма. Визуализируйте результаты и проведите сравнение двух алгоритмов (можно использовать как визуальное сравнение, так и метрики: средний размер кластеров, межкластерное и внутрикластерное расстояние, и другие).

Проанализируйте различия в поведении двух алгоритмов, сделайте вывод, какой из них лучше подходит для поставленной задачи.